

ANLP | תרגיל 1

Or Israeli May 5, 2026

שאלה 1

אביא שלוש דוגמאות לשלושה דאטהסטים "מענה על שאלות" שימדדו את רמת ההבנה האינטרניסית של המודל את השפה ואת המשמעות שלה. למעשה במקום למדוד את מידת היכולת של המודל לעשות משימה ספציפית, אנחנו מודדים אותו על ההבנה שלו את הקונספטים המופשטים שיסייעו לו לעשות כל עבודת שפה שהיא. אני חושב שאולי השוואה טובה היא מבחן דפ"ר, שמתיימר למדוד "יכולת מוחית" ולא ידע במשימה שלאחר מכן יכשירו אליה במהלך השירות. א. דאטהסט שמצאתי מעניין למדידת תכונות אינטרסיות הוא <https://huggingface.co/datasets/lucasmccabe/logiqa> שבוחן את *llm* על שאלות הגיון והבנת הנקרא, שמבוסס על מבחן מסוים של שירות המדינה הסיני. המודל מקבל קונטקסט, באורך של משפט עד פסקה ושאלה על הקונטקסט, ואז לבחור בין תשובות שונות. לדוגמה:

When a young American diplomat visited China, he asked him an embarrassing question: how could the Orientals be so puzzling. The Chinese official smiled, and then gently answered him: regarding the lack of observation of Westerners In terms of their nation, it is puzzling.

Which of the following options best reflects the point explained by Chinese officials: 0. לאחר מכן נשאלת השאלה: 0. להתשובות הניתנות הן

"Not only Chinese, but all Orientals are also puzzling.",

"Most Americans cannot understand Chinese culture.",

"What people don't observe may be due to the shallowness of the observation, rather than the obscurity of the thing itself.",

"Since the United States and China resumed diplomatic relations, many Chinese have gradually distrusted Americans."

והמודל צריך לבחור בין האופציות. ביצועים טובים על הדאטהסט הזה ישקפו הבנה של שפה וסיפור ויכולת למצוא את המשמעות מתוך הסיפור ולהסיק בעקבותיו מסקנות לוגיות. בניגוד למדידת ידע, מדובר בטקסטים "סגורים", שאדם ומכונה שקידדה את השפה והמשמעויות שלה לתוך עצמה אמורים לדעת לנתח בהצלחה. כלומר, אין יכולת להצליח במשימה הזאת דרך ניחושים על סיפורים על סינים, או על דיפלומטים - צריך "לעכל" משמעות וסיבתיות לשונית. ב.

דאטהסט אחר, שמודד תכונות צנועות יותר, הוא דאטהסט מסוג שראינו בשיעור-*rte*. המודל מקבל שני משפטים ואמור להכריע האם הם סותרים או גוררים אחד את השני. דוגמה פשוטה היא

No Weapons of Mass Destruction Found in Iraq Yet.

Weapons of Mass Destruction Found in Iraq.

וכמובן שפה שני המשפטים סותרים ולכן התוויית היא 0.

ביצועים טובים על המודל הזה ישקפו הבנה אינטרזית בסיסית של שפה - האם משפט א' מחייב לוגית את משפט ב' או לא. בהרבה מובנים זו משימה קלה יותר מהמשימה הקודמת, גם מהטעם הפשוט שיש רק 2 תוויות ולא 4, וגם בגלל שרמת ההבנה הנדרשת נמוכה יותר - משפטים סותרים בהכרח לא ישמעו דומים ולא יצטרכו לעמוד על דיוקים לוגיים - או שמדובר בהפכים או שמדובר במשפטים זהים או מכילים לוגית. <https://huggingface.co/datasets/SetFit/rte>. ג. הסוג השלישי שרציתי לדבר עליו הוא *wsc*, שמתמקד בהבנת שפה ברמה הכי טכנית (מבין השלושה, לפחות) - נותנים למודל פסקה עם כינוי גוף כלשהו כמו *they*, ושואלים אותו למי כינוי הגוף מתייחס, מתוך שתי אופציות אפשריות. מודל שינבא בהצלחה על הדאטהסט הזה כנראה הבין את חלקי המשפט הבסיסיים

והצליח למצוא הקשרים בין חלקי המשפט והטקסט השונים. כדי להבין גם את זה, לא מספיק לנחש לפי המידע, אלא חייבים להבין את התפקיד, המשמעות והמיקום של כל פועל ואיך הוא משפיע על משמעות כינוי הגוף.

לדוגמה: https://huggingface.co/datasets/marcov/winograd_wsc_wsc285_promptssource

שאלה 2

מאפשרים לקחת את הפלט של מודל השפה ולאמת אותו על ידי מבחנים דטרמיניסטים יותר כמו קידוד לשפת הוכחות מתמטיקה פורמלית או בניית יוניט טסט לקוד. אפשר לעשות את זה רק בסביבת אימון או בסביבת אימון ובדיקה בייחד. יתרון ברור של השיטה הזאת הוא היכולת להבטיח את תקינות הפלט המוחלטת באמצעים זולים מבחינת קומפיוט. כדי להריץ יוניט טסט שבדוק קומפוננטה כנראה נדרש פחות כוח עיבוד מאשר מו'נירוט הפלט עצמו. בניגוד נניח לשיטות באייסיאניות שגם מבקשות לספק אמינות כלשהי - פה אנחנו נוכל להגיד בוודאות האם זה נכון או לא. השילוב בין מנוע סטטיסטי "יצירתי" למנוע "פורמלי", יכול להיות עוצמתי ולהבטיח תוכנה/עבודה מתמטית אמינה שיכולה לרוץ בלי אדם בלולאה.

צוואר בקבוק שאני צופה פה הוא בעיקר בחוסר התיאום בין סוגי הפלטס - הפלט של מודל השפה תלוי ב tpu/gpu , אבל בשביל להריץ את היוניט טסט נדרש ככל הנראה להרים קונטיינר כלשהו מאחורי הקלעים שיריץ על המעבד שלו את זה, ויחשוף יותר ישירות את הזכרון ואת המכונה, ולא רק ישלח ויקבל טקסט שיזין לרשת. זה עלול להכביד הן ביצועית והן אבטחתית על המחשב המארח. באופן כללי כן אפשר לעשות פריליזציה, כפי שאנחנו מחשבים על כל מחשב המון תהליכים.

שיטה אחרת להאצה בזמן הסקה היא למידת על ידי ייצור ודגימה של מגוון של נתיבי הסקה - דרכי מחשבה, שונים עבור אותה שאלה. לאחר מכן המודל ינסה לערוך הצבעה בין דרכי החשיבה השונות על התשובה הנכונה וילך עם דעת הרוב או באמצעות מנגנון אגרציה אחר כדי לקבוע את הפלט הסופי למשתמש. השיטה מאפשרת להגדיל את כמות המחשוב בזמן הסקה ומשפרת את האמינות של הפלט החסרון פה הוא גם צוואר הבקבוק והוא די ברור - גנרט של טקסט הוא דבר יקר על משאב במחשור תמידי - tpu/gpu - בכל שרשרת מחשבה נוספת שהוא מייצר כדי לשפר את התשובה הוא יכל לשרת לקוח נוסף. מכיוון שהשיטה מרחיבה אלמנט שקיים כבר שהוא יכולת לג'נרט טקסט במקביל, היא מותאמת מאוד למקביליות.

שיטה נוספת היא back tracking שהוצגה ב $O1$, במסגרתה המודל מזהה שניתן לו קלט שידרוש ממנו תכנון וחשיבה מורכבת, ומפעיל חשיבת מטא על מנת לתכנן את הפלט. קודם הוא מתכנן את שלבי העבודה, באופן דומה לאדם שביקשו ממנו להוציא אל הפועל משהו מורכב, ואז הוא בודק את עצמו אחרי כל שלב - האם הפלט מתאים לתוכנית העבודה. אם לא - הוא חוזר אחורה ומתחיל שוב. באטלנק עיקרי שאני צופה פה הוא חזרות בלתי נגמרות של "לא בטוח", שהאמת חוויתי עם קלוד כבר מסתבר פעמים. אם הוא לא מוצא תשובה שהוא בטוח בה הוא יכול לבזבז המון המון קומפיוט בדרך בלי לתת שום ערך למשתמש. זה לא ממש תומך במקביליות, כי זה בדיוק ההגדרה לפיתוח ווטרוול. מחלקים לשלבים שתלויים אחד בשני.

חלק מעשי

1. הרצתי גריד על שלושה הייפרפרמטרים מכל משפחה, על שלוש אופציות לכל הייפרפרמטר, כדי למצוא את השילוב המיטבי (או המיטבי שמשאבי המחשוב המוגבלים שלי אפשרו לי).

המודל הכי טוב באימון הוא גם הכי טוב בוולידציה עם 5 אפוקים, מקדם למידה של 5×10^{-5} , וגודל באצ' של 64, מה שמרמז שלא היה אוברפיט.

2.

התוצאה הכי גרועה התקבלה עם אפוק אחד, קצב למידה של 0.0005 וגודל באצ' של 64, עם דיוק של 0.6838, שהוא למעשה היחס בין התוויות החיוביות לשליליות - רוצה לומר, המודל למד לחזות רק 1 על כל המשפטים, להגיד שכל המשפטים דומים בגלל שהוא ראה דאטהסט עם הטייה לכיוון הזה, וצעדי הלמידה היו גדולים מדי מכדי לתקן אותו בטווח של אפוק אחד. מעניין לציין שניסיתי לתקן את העניין כך שהכשלון יהיה פחות טכני ויותר מעניין - עם משקלי קלאסים, כך שייתן לטעות במחלקה 0 משקל גדול יותר, אבל נראה שבכל מקרה המודל הגרוע ביותר מתכנס לשם ללהגיד 1.

התוצאה הכי טובה הייתה כאמור עם 5 אפוקים, מקדם למידה של 5×10^{-5} , וגודל באצ' של 64, עם דיוק של 0.86765 וציון $f1$ של 0.9069, שאני חושב שאפשר להגיד שהוא תוצאה לא רעה.

כך שנראה שאין גודל באצ' טוב באופן אבסולוטי לכל הרצה שהיא.

מזה שהמודל הכי טוב מתקבל מהרצה של מספר האפוקים המקסימלי אני למד שהיה אפשר להגדיל את זמן האימון ואולי להרוויח עוד קצת וממקדם הלמידה אני למד שהוא מספיק גדול ככל הנראה בשביל להזיז את המחט אבל מספיק קטן כדי למצוא נקודת מינימום מקומית.

מבדיקה של 59 זוגות המשפטים מסט הולידציה נראה שגם המודל היותר טוב מתקשה עם משפטים שמכילים ישויות רבות שהמילים מתקשרות אליהן באופנים שונים. ככלל נראה שיש התקשות עם משפטים "מסורבלים" - שהחלקים החשובים שלהם רחוקים אחד מהשני.

כדי שתוכלו לראות את התרגום בין הריצות בתמונה של הלוס לפרמטרים השונים, צירפתי את

expended_sweep_table.csv